Projet de MRR

Présenté par Alicia WANG et Sara HADOUANI

Présentation de l’étude

- Analyse du niveau de gravité de différents troubles psychiatriques chez une personne en fonction de ses diverses données génétiques et cliniques.

- 4 niveaux de trouble psychiatrique :
  aucun
  dépression
  trouble bipolaire
  schizophrénie

Présentation du data set

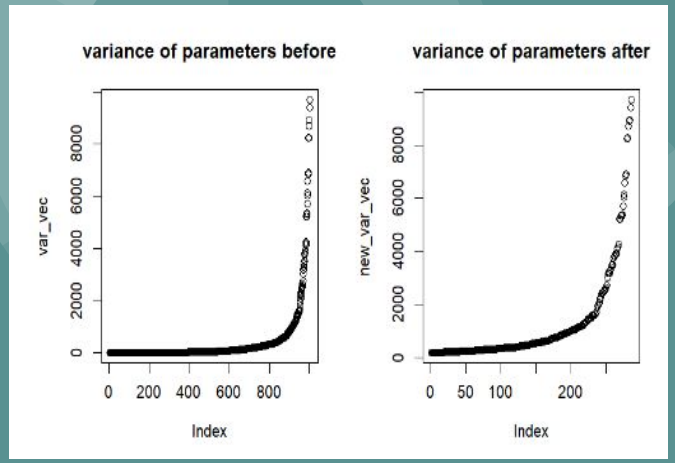
- 205 observations et 1041 variables
- Pas de valeur manquante
- Variables catégorielles et numériques
- Présence de valeurs infinies
- Présence de variables administratives inutiles

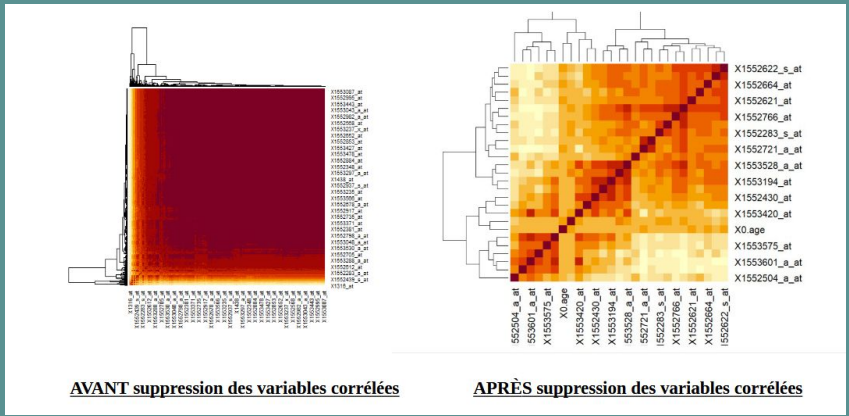
Nettoyage du data set

- Transformation des variables catégorielles (gender, tissu, race et disease state)
- Suppression des variables administratives
- Quand au moins 30% des valeurs d'une variable valent Inf
  -> Suppression de la variable
  Sinon
  -> Remplacement par la médiane
- Réduction de l'amplitude des valeurs (critère: rapport entre le quantile à 99 % et la médiane > 10^6) avec une transformation logarithmique
- Détermination des valeurs aberrantes avec l'écart interquartile :
  si au moins 40% des valeurs sont jugées aberrantes -> suppression de la variable
  sinon -> remplacement par la médiane

Nettoyage du data set

- Suppression des variables à faible variance
- Suppression des variables avec une corrélation de 0.7



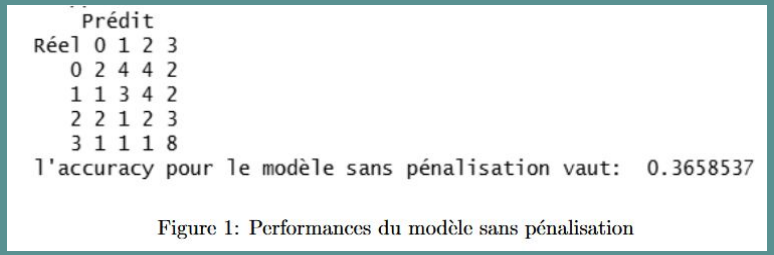


Démarche générale

- Séparation du data set en deux: 80% pour l'entraînement et 20% pour les tests
- Génération des modèles avec les données d'entraînement
- Calcul pour chaque catégorie de trouble psychiatrique la probabilité que la variable cible y appartienne -> catégorie prédite = catégorie dont la probabilité est la plus élevée
- Calcul de l'accuracy sur les prédictions à partir des données du test

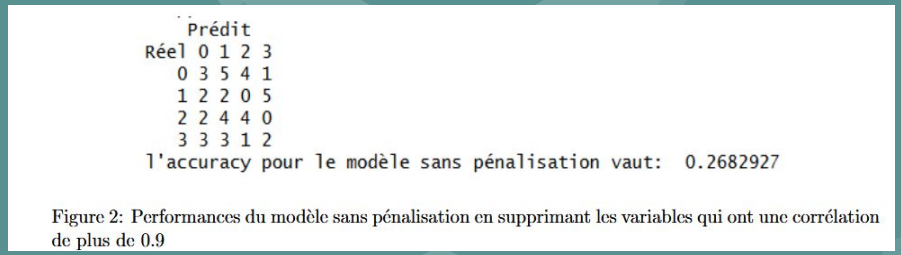
Première méthode: régression logistique multiple sans pénalisation

- Choix de ce modèle car la variable cible est catégorielle
- Calcul de l'accuracy (pourcentage des cas bien prédits)



```
    Prédit
Réel 0 1 2 3
   0 2 4 4 2
   1 1 3 4 2
   2 2 1 2 3
   3 1 1 1 8
l'accuracy pour le modèle sans pénalisation vaut:  0.3658537
```

Figure 1: Performances du modèle sans pénalisation



```
    Prédit
Réel 0 1 2 3
   0 3 5 4 1
   1 2 2 0 5
   2 2 4 4 0
   3 3 3 1 2
l'accuracy pour le modèle sans pénalisation vaut:  0.2682927
```

Figure 2: Performances du modèle sans pénalisation en supprimant les variables qui ont une corrélation de plus de 0.9

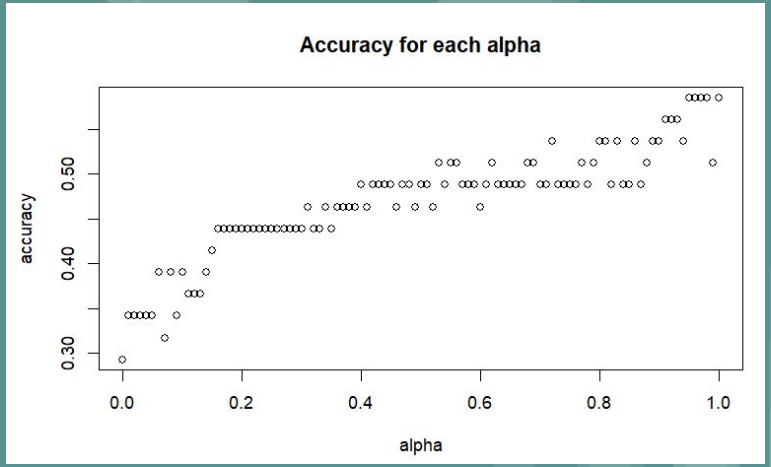
-> Accuracy pas satisfaisant
On va garder les variables corrélées mais on va effectuer des pénalisations

Deuxième méthode: Elastic Net

- Génération pour des valeurs de alpha allant de 0 (Ridge) à 1 (Lasso) avec un pas de 0.01
- Utilisation du lambda qui minimise l'erreur moyenne de prédiction
- alpha choisi = celui qui donne la meilleure accuracy

```
Meilleure accuracy vaut:  0.6341463
Meilleure accuracy pour alpha =  0.87
Précision pour ce alpha =  0.6366162
```

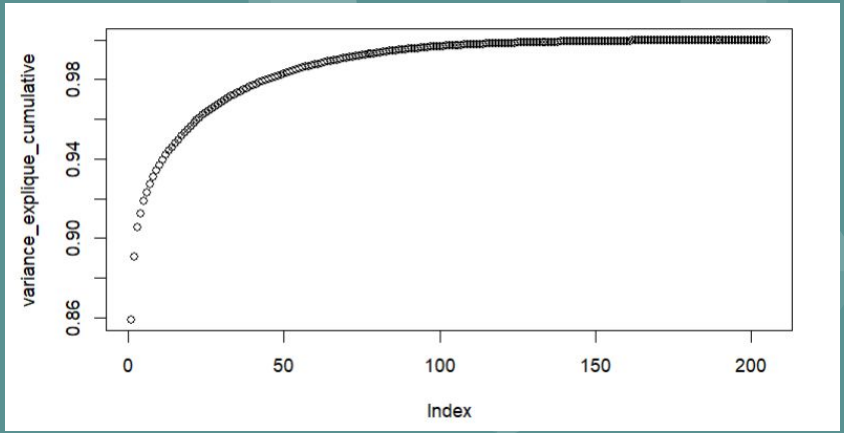
Figure 8: Valeurs des performances du modèle avec Elastic Net



alpha = 0.87 -> cohérent car entre Ridge et Lasso on a eu une meilleure performance avec Lasso

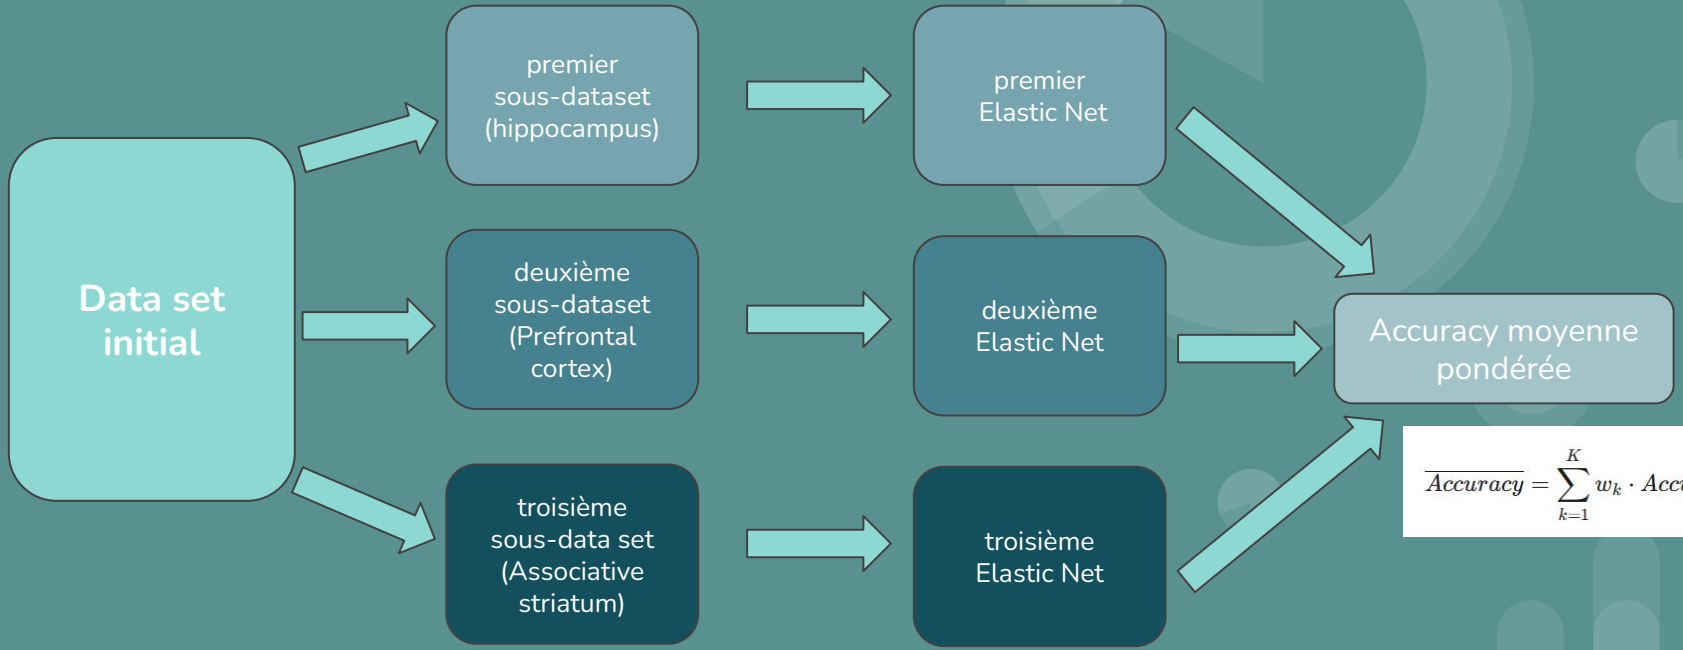
Troisième méthode: PCA + régression sans pénalisation

- Réduction du nombre de dimensions du data set avec PCA
- Utilisation des 50 premières composantes principales




```
    Prédit
Réel 0 1 2 3
   0 6 2 4 3
   1 4 4 1 2
   2 3 2 4 0
   3 0 1 0 5
l'accuracy pour le modèle après avoir effectué PCA sur le data set vaut:  0.4634146
```

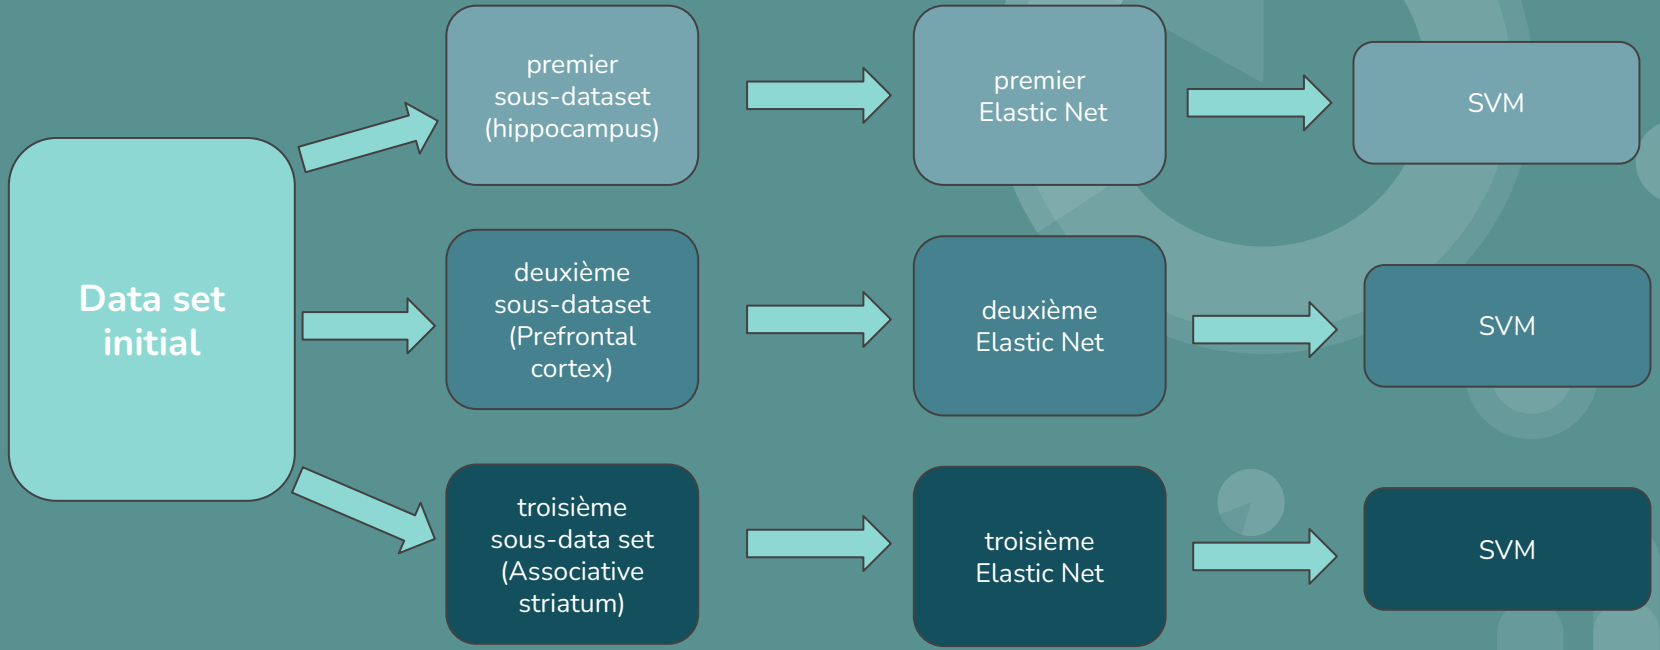
Quatrième méthode: division du data set + Elastic Net



$$\overline{Accuracy} = \sum_{k=1}^{K} w_k \cdot Accuracy_k$$

l'accuracy moyenne ponderée vaut: 0.6146341 alors que l'accuracy du premier Elasic Net (sans division du data set) vaut: 0.4634146

Cinquième méthode: division du data set + Elastic Net




```
Accuracy globale pondérée après avoir effectué SVM: 0.5128205
```

Conclusion

Régression sans pénalisation

Elastic Net

Division du data set + Elastic Net

PCA + régression sans pénalisation

Division du data set + Elastic Net + SVM



MEILLEUR MODÈLE