Hadouani Sara
Wang Alicia

Rapport de projet MRR sur l'étude des troubles psychiatriques

Présentation de l'étude

Notre étude porte sur l'analyse du niveau de gravité de différents troubles psychiatriques chez une personne en fonction de ses diverses données génétiques. Les différents niveaux étudiés sont les suivants, rangés du moins grave au plus grave: absence de trouble (« control »), dépression (« major depressive disorder»), trouble bipolaire (« bipolar disorder ») et schizophrénies (« schizophrenia »). Le dataset est issu d'une étude américaine qui a analysé différentes parties cérébrales en lien avec ces troubles.
Pour cela, la première étape consiste à analyser et réaliser un traitement préalable des données afin de les rendre exploitables pour construire des modèles qui expliquent qualitativement l'influence des gènes sur le niveau de gravité des troubles psychiatriques, notre variable cible.

Analyse du dataset

Le dataset est constitué de 205 observations et 1041 variables et il n'y pas de valeur absente.
Le nombre de paramètres montre bien qu'il y a un processus de nettoyage à effectuer. Nous distinguons des variables numériques et catégorielles.

En premier lieu, nous avons remplacé notre variable cible, initalement des chaînes de caractères, par une échelle de valeurs traduisant la gravité des troubles : 0 pour l'absence de trouble, 1 pour la dépression, 2 pour le trouble bipolaire et 3 pour la schizophrénie afin de les rendre plus exploitables. De même pour les autres variables catégorielles : pour l'ethnicité (0 pour « White » et 1 pour « Black ») et pour le genre (0 pour « Male » et 1 pour « Female »).

Ensuite, nous avons supprimé toutes les variables administratives qui ne sont pas utiles pour notre analyse des facteurs associés aux troubles psychiatriques comme le nom de l'institut de recherche ou le nom des chercheurs mais également les variables catégorielles de tous types qui ne prennent qu'une unique valeur.

Les variables restantes sont numériques. Pour choisir lesquelles garder, nous nous sommes basées sur plusieurs critères :

1. Le nombre de variables infinies sachant qu'il n'y pas de variables NA dans tout le dataset
   Nous avons considéré que si plus de 30 % des observations d'une variable sont infinies alors celles-ci risqueraient de détériorer la qualité de notre analyse. Il faudrait alors la supprimer. En dessous de ce seuil choisi, les observations égales à l'infini seront égales à la médiane des valeurs finies. De cette manière, elles n'influenceront pas les autres observations.

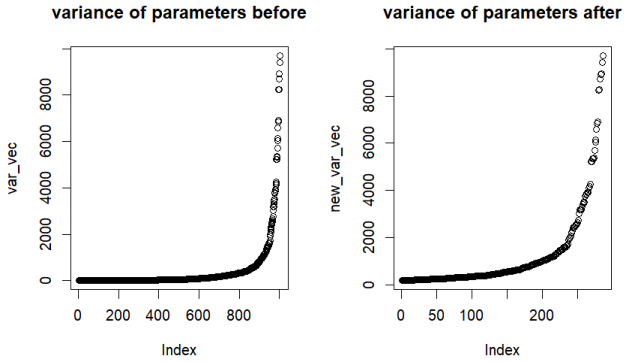
2. Le nombre de valeurs abérrantes
   Les valeurs sont abérrantes si elles sont en dessous ou au dessus d'un certain seuil dépendant de l'interquartile et des quartiles à 25 % ou 75 %. De même que pour les cas des valeurs infinies, si le nombre de valeurs aberrantes dépassent 40 % des observations alors nous supprimons la variable. Son nombre trop important risquerait de fausser notre étude. Nous pourrions aussi les remplacer par la valeur médiane mais cela n'aurait plus d'intérêt car nous obtiendrions une variance très faible avec au moins 40 % des observations égales à une seule valeur.

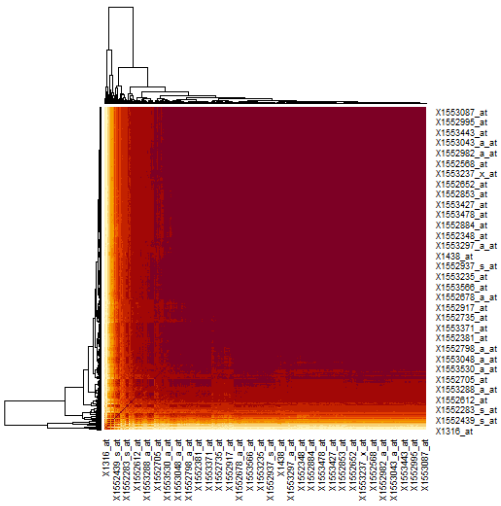
   Toutefois, il est à noter que l'amplitude des observations peut être très grande, c'est pourquoi avant de supprimer une variable contenant un certain nombre de valeurs supposées aberrantes, on vérifie si le rapport entre le quantile à 99 % et la médiane est plus grand que 10^6, seuil que nous avons jugé pertinent pour décider de réduire l'amplitude des valeurs.
   Si le rapport est supérieur à 10^6 alors nous réduisons l'amplitude des valeurs en appliquant le logarithme de base 10.
   C'est après la réduction ou non de l'amplitude des valeurs que nous calculerons la proportion de valeurs aberrantes et que nous déciderons ou non de supprimer la variable en question.

Enfin, si la proportion des valeurs aberrantes ne dépassent pas les 30 % des observations ou que celle des valeurs infinies ne dépassent pas 30 % des observations alors nous décidons de ne pas supprimer la variable mais d'affecter à ces valeurs aberrantes, la médiane pour ne pas biaiser les autres observations.

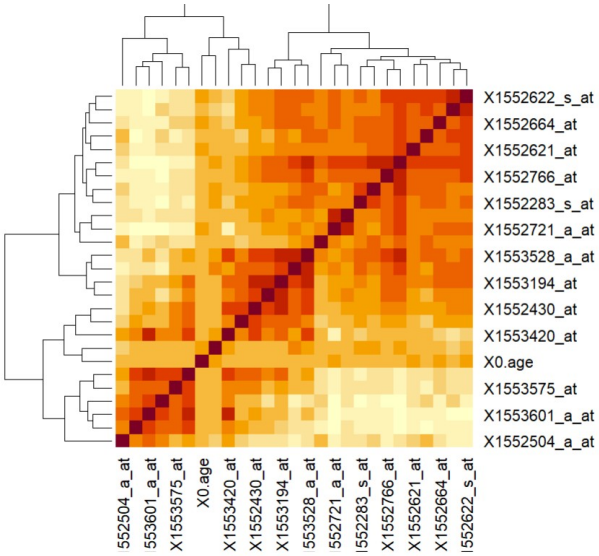
Pour chaque variable numérique, nous faisons les vérifications venant d'être décrites et qui sont contenues dans une fonction.

Après cette étape de sélection, il reste 1011 variables ce qui est mieux mais toujours améliorable.
C'est pourquoi, nous envisageons de supprimer par la suite, les variables de faible variance. Nous visions en particulier celles dont la variance est inférieure à la médiane car nous voulons vraiment réduire le nombre de paramètres.
Le graphique le plus à gauche montre qu'il y a énormément de variables de faible variance. La variance minimale avant suppression valait 0 et après elle équivaut à 46,4 ce qui ne semble pas être un filtrage trop important. Il ne reste plus que 509 variables ce qui est beaucoup mieux mais toujours supérieur au nombre d'observations.





Reste à supprimer les variables fortement corrélées car le nombre de variables est encore trop important. Le heatmap de gauche, très rouge, montre beaucoup de variables corrélées et beaucoup de bruit.
Nous supprimons donc toutes celles qui ont un coefficient de corrélation supérieur à 0,7 en excluant le cas où il vaut 1 car il compare la même variable.



AVANT suppression des variables corrélées **APRÈS suppression des variables corrélées**

Finalement, nous nous retrouvons avec 27 variables pour le même nombre d'observations en prenant la médiane. Néanmoins, le heatmap présente encore quelques signes de faibles corrélations. On en conclut que nous n'avons pas effectué de filtrage trop important risquant une perte d'information mais assez pour limiter le nombre de corrélations.
Notre traitement de données nous permettra d'obtenir des analyses plus précises et qualitatives pour notre étude.