Rapport MRR sur les modèles

Alicia Wang et Sara Hadouani

December 7, 2025

1 Introduction

Dans cette deuxième partie du projet, nous allons montrer et justifier les méthodes utilisées pour élaborer un modèle qui prédise avec les meilleures performances possibles la variable cible. Nous rappelons que notre étude porte sur l'analyse du niveau de gravité de différents troubles psychiatriques chez une personne en fonction de ses diverses données génétiques.

2 Présentation des méthodes utilisées

2.1 Régression logistique multiple sans pénalisation

Comme notre variable cible représente quatre catégories différentes, nous avons décidé de commencer par réaliser une régression logistique multiple. On a commencé d'abord par un modèle sans pénalisation. Pour cela, on a divisé notre data set en deux: 80% des données pour l'entraînement et 20% pour le test. On a créé un modèle qui, pour chaque catégorie de trouble psychiatrique, donne la probabilité que la variable cible y appartienne. Ensuite, le modèle affecte à la variable cible la catégorie dont la probabilité est la plus élevée. Puis, avec les données de test, on a calculé les performances du modèle, en regardant la valeur de l'accuracy. Elle représente le pourcentage des cas bien prédits par le modèle.

```
      Prédit
Réel 0 1 2 3
   0 2 4 4 2
   1 1 3 4 2
   2 2 1 2 3
   3 1 1 1 8
l'accuracy pour le modèle sans pénalisation vaut:  0.3658537
```

Figure 1: Performances du modèle sans pénalisation

```
      Prédit
Réel 0 1 2 3
   0 3 5 4 1
   1 2 2 0 5
   2 2 4 4 0
   3 3 3 1 2
l'accuracy pour le modèle sans pénalisation vaut:  0.2682927
```

Figure 2: Performances du modèle sans pénalisation en supprimant les variables qui ont une corrélation de plus de 0.9

On a trouvé une valeur de 0.36 environs, ce qui signifie que seul 36% des données de test ont été bien prédites, ce qui n'est pas satisfaisant. Nous soupçonnons avoir supprimé trop de variables lorsque l'on a enlevé celles qui ont une corrélation de plus de 0.7. On a donc décidé de ne pas les retirer du data set que les variables qui ont une corrélation de plus de 0.9, mais on n'obtient un accuracy de 0.26, ce qui n'est pas satisfaisant non plus.

On a donc décidé de garder les variables corrélées, mais comme notre data set dans ce cas contient beaucoup plus de variables que d'observations, on a décidé d'effectuer différentes pénalisation et voir laquelle permet d'améliorer notre modèle.

2.2 Régression logistique multiple avec Ridge

La régression Ridge consiste à réduire la valeur absolue des coefficients du modèle en ajoutant une pénalité qui dépend d'un facteur λ que l'on doit choisir. Comme précédemment, on a divisé le data set en deux. On a standardisé les données d'entraînement et de test puis a effectué une validation croisée avec 10 plis sur les données d'entraînement pour trouver le paramètre de régularisation λ qui minimise l'erreur moyenne de prédiction sur les 10 plis. On constate par ailleurs que la déviance varie entre 2.75 et 2.83.

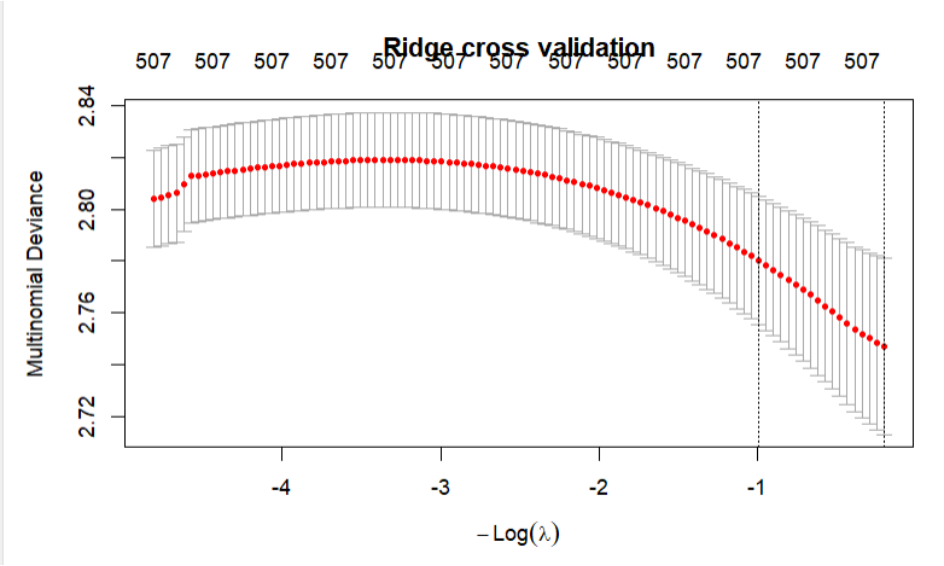


Figure 3: Valeurs de la déviance en fonction de -log(λ)

Ensuite, on a généré le modèle avec la pénalisation de Ridge grâce aux données d'entraînement. Puis, on a testé les performances sur les données de test.

```
La précision de prédiction de control est  0.3529412
La précision de prédiction de major depressive disorder est  0.25
La précision de prédiction de bipolar disorder est  0.2142857
L'accuracy pour Ridge est : 0.3414634
La précision de prédiction de schizonphrenia est  0.6666667
La précision moyenne vaut  0.3709734
```

Figure 4: Performances obtenues avec la méthode Ridge

On a trouvé un accuracy de 0.34, ce qui signifie que la pénalisation de Ridge n'a pas permis d'améliorer le modèle. On a de plus calculé la précision de chaque catégorie. Cette valeur mesure la fiabilité de prédiction de chaque catégorie: pour chacune prédite, on calcule combien correspondent à la catégorie réelle. On a déterminé également la moyenne des précision obtenues et elle vaut 0.37, ce qui est assez faible.

2.3 Régression logistique multiple avec Lasso

La régression Lasso consiste également à réduire la valeur absolue des coefficients du modèle en ajoutant une pénalité qui dépend d'un facteur λ que l'on doit choisir, mais elle permet de supprimer des variables, contrairement à la méthode Ridge. Comme précédemment, on a divisé le data set en deux. On a

standardisé les données d'entraînement et de test puis on a effectué une validation croisée avec 10 plis sur les données d'entraînement pour trouver le paramètre de régularisation λ qui minimise l'erreur moyenne de prédiction sur les 10 plis.

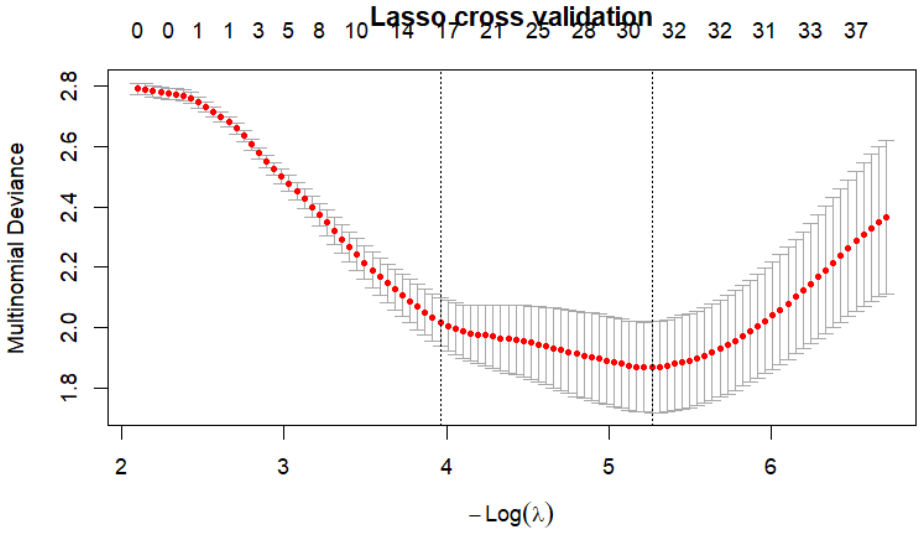


Figure 5: Valeurs de la déviance en fonction de -log(λ)

On constate qu'elle varie entre 1.9 et 2.8, donc le modèle qui utilise Lasso présente des déviances plus faibles que celui qui utilise Ridge. Ensuite, on a généré le modèle avec la pénalisation de Lasso grâce aux données d'entraînement. Enfin, on a testé les performances sur les données de test.

```
La précision de prédiction de control est  0.4166667
La précision de prédiction de major depressive disorder est  0.5
La précision de prédiction de bipolar disorder est  0.7
La précision de prédiction de schizonphrenia est  0.8181818
L'accuracy pour Lasso est : 0.6097561
La précision moyenne vaut  0.6087121
```

Figure 6: Valeurs des performances du modèle avec la régression Lasso

On obtient un accuracy et une précision moyenne de 0.6, ce qui est nettement mieux que les résultats des deux modèles précédents. Le nombre de variables restantes est de 81 contre les 27 qui restaient après avoir supprimé celles corrélées, ce qui signifie qu'on en avait supprimé trop auparavant.

```
Le nombre de variables considérées pour le modèle Lasso est 81 contre 505 avant.
```

Figure 7: Nombre de variables restantes avec Lasso

2.4 Régression logistique multiple avec Elastic Net

On a décidé d'explorer d'autres modèles avec Elastic Net pour en cherher un qui pourrait être encore meilleur. Elastic Net est une méthode de régularisation qui combine les méthodes Ridge et Lasso via un paramètre de mélange α. On a généré différents modèles pour un α qui varie de 0 à 1 avec un pas de 0.01 et un λ qui minimise l'erreur moyenne de prédiction. Ensuite, on a déterminé la valeur de α pour laquelle on a le meilleur accuracy et on a observé la précision moyenne associée, qui est la moyenne de la précision de chaque catégorie.

On a trouvé que la meilleure accuracy est obtenue pour un α égal à 0.87 et elle vaut 0.63. La précision moyenne du modèle généré avec ce α vaut 0.64. Donc ce modèle est légèrement meilleur que

```
Meilleure accuracy vaut:  0.6341463
Meilleure accuracy pour alpha =  0.87
Précision pour ce alpha =  0.6366162
```

Figure 8: Valeurs des performances du modèle avec Elastic Net

celui obtenu avec la méthode Lasso. On constate qu'il reste 70 variables avec ce modèle contre les 27 qui restaient après avoir supprimé celles corrélées.

```
Le nombre de variables considérées est 70 contre 505 avant.
```

Figure 9: Nombre de variables restantes avec Elastic Net

3 Conclusion

Pour conclure, c'est le modèle de prédiction de Elastic Net qui permet de trouver le meilleur modèle avec pénalisation. Non seulement il comprend les cas des pénalisations de Ridge et de Lasso mais il teste également des modèles en prenant en compte ces deux pénalisations en proportions différentes. On a ainsi supprimé les variables les moins pertinentes, ce qui nous a permis d'obtenir les meilleurs résultats de prédiction.